

01

期末專案

DEFAULT OF CREDIT CARD CLIENTS

報 告 人： 郭 哲 瑋

Nov 8, 2026

02

資料集
DATA SET

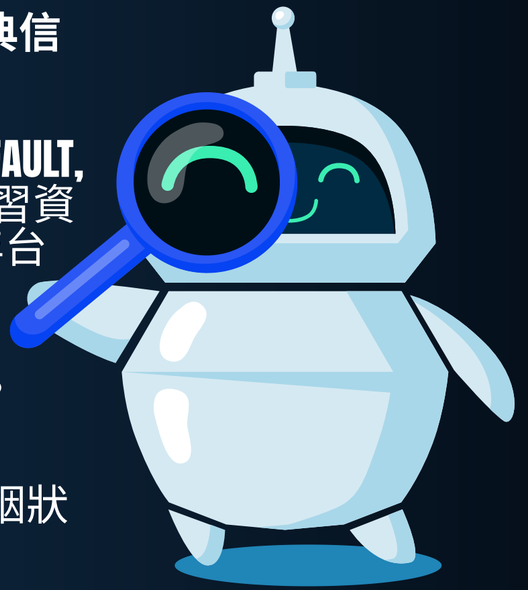
資料庫名稱：**DEFAULT OF CREDIT CARD CLIENTS (UCI / KAGGLE 經典信用卡違約資料集)**

來源與背景：該資料集是預測違約機率（**PROBABILITY OF DEFAULT, PD**）或客戶信用風險時，最經典、被最廣泛使用的機器學習資料集。由 **I-CHENG YEH** 與 **CHE-HUI LIEN** 收集，資料來自 **2005**年台灣的信用卡客戶。

資料規模：共 **30,000** 筆實例、**23～24** 個變數（無遺漏值）。

主要特徵：

- 個人基本資料：額度（**LIMIT_BAL**）、性別、教育程度、婚姻狀況、年齡。
- 歷史還款紀錄：前 **6** 個月（**4**月至**9**月）的繳款狀態。
- 帳單金額與還款金額：前 **6** 個月的每月帳單與實際繳款金額。
- 目標變數（**TARGET**）：下個月是否違約（**DEFAULT PAYMENT NEXT MONTH**：**1** 代表違約，**0** 代表未違約）。



注意事項
CONSIDERATIONS

1.資料不平衡（Class Imbalance）
實際資料中「未違約」的客戶遠多於「違約」的客戶。訓練模型時常需要搭配重取樣（如 SMOTE）或調整成本敏感權重（Cost-sensitive learning）。

2. 模型選擇
針對該資料集實證研究上，XGBoost、LightGBM、Random Forest 等樹狀模型，或是結合 XAI（可解釋性AI）來分析哪幾項特徵導致違約，通常比單純的邏輯回歸有更好的預測與解釋效果。

3. 機器學習模型比較
- 常用來測試各種分類演算法，如羅吉斯迴歸（Logistic Regression）、隨機森林（Random Forest）、支援向量機（SVM）、梯度提升機（GBM / LightGBM）與類神經網路。
- 由於資料類別不平衡，評估指標通常不只看準確率（Accuracy），而會著重在 ROC-AUC、F1-Score、Precision-Recall Curve。





資料欄位
DATA COLUMN

1. 個人基本屬性（Demographic）
- ID：客戶編號
- LIMIT_BAL：新台幣信用額度（包含個人與家庭附卡額度）
- SEX：性別（1 = 男性，2 = 女性）
- EDUCATION：教育程度（1 = 研究生，2 = 大學，3 = 高中，4 = 其他等）
- MARRIAGE：婚姻狀況（1 = 已婚，2 = 單身，3 = 其他）
- AGE：年齡（歲）

2. 過去還款紀錄（Repayment Status, 2005年4月–9月）

PAY_0 至 PAY_6：各月份的繳款狀態（PAY_0 為 9 月，PAY_2 為 8 月……以此類推）- 負數（如 -1 或 -2）通常代表按時全額繳款或超額/無消費
- 0代表按最低應繳金額繳款
- 正數（1 至 9）代表延遲繳款的月數（例如 1 表示遲繳 1 個月，2 表示遲繳 2 個月）

3. 帳單金額（Bill Statement Amounts, 2005年4月–9月）

BILL_AMT1 至 BILL_AMT6：各月份的信用卡帳單結算金額（新台幣）（BILL_AMT1 為 9 月帳單，BILL_AMT2 為 8 月帳單…）

4. 過去繳款金額（Previous Payment Amounts, 2005年4月–9月）

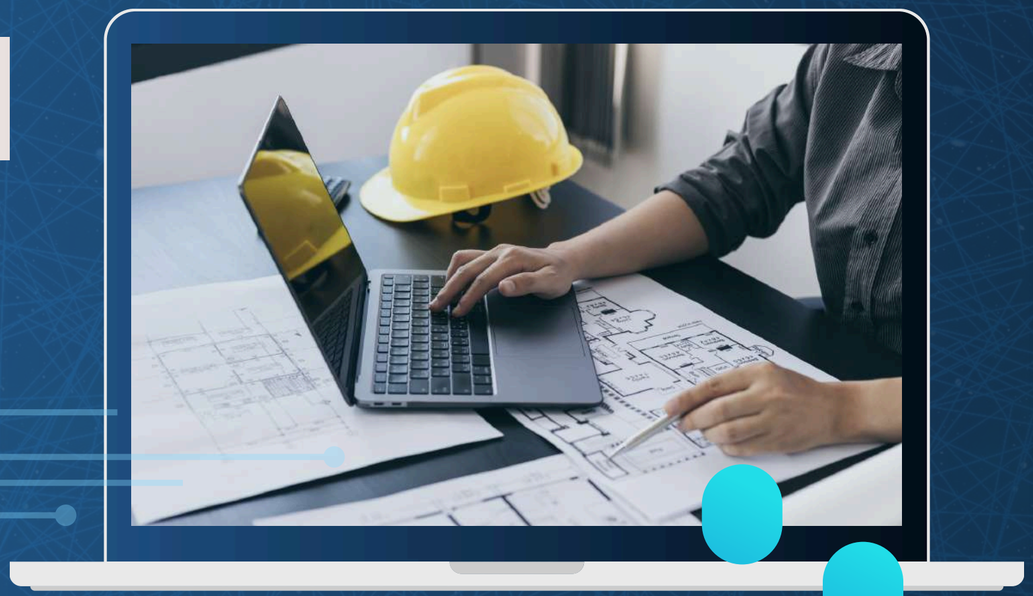
PAY_AMT1 至 PAY_AMT6：各月份實際繳交的金額（新台幣）（對應前一個月的帳單繳費狀況）

5. 目標變數（Target）

default.payment.next.month：次月是否違約（1 = 違約，0 = 未違約）

分析流程
PROCESS

05



1. 問題定義
2. 資料收集與探索
3. 資料前處理與特徵工程
4. 模型選擇與訓練



問題定義
PROBLEM DEFINITION

明確目標

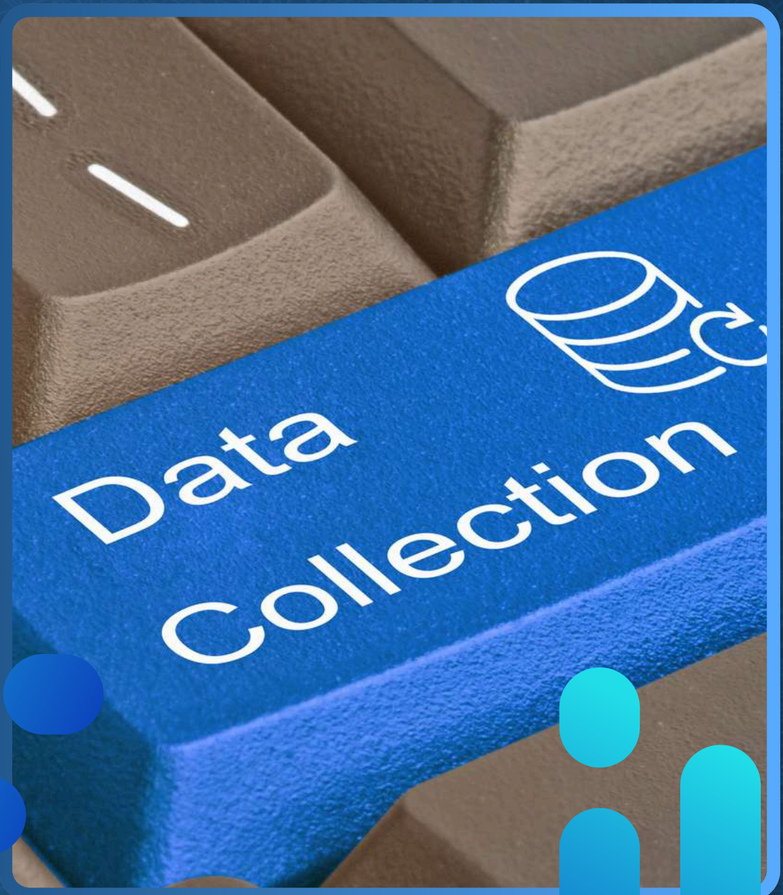
將商業或實際問題轉化為機器學習任務（例如：分類、迴歸、分群）。

- 任務：二元分類，目標變數 default.payment.next.month
- 輸出：違約與否（0/1）及違約機率（PD）

設定指標

確定評估成功的關鍵績效指標（KPI），如準確率（Accuracy）、F1-score 或均方誤差（MSE）。

- 指標：Accuracy、Precision、Recall、F1、AUC、Log Loss



資料收集與探索
DATA COLLECTION & EDA

資料獲取

資料來自 UCI，也可以在 Kaggle 下載，是 2005 年 4 月到 9 月台灣信用卡客戶的資料，共 3 萬筆、25 個欄位。欄位分成四類：額度與人口統計資料，如額度、性別、教育程度、年齡；過去 6 個月的還款狀態；6 個月的帳單金額；以及 6 個月的實際繳款金額。

探索性資料分析（EDA）

- 資料沒有遺失值，但違約只占 22.12%，屬於不平衡資料。
- 最近一個月有沒有逾期，是區分違約最明顯的訊號：沒有逾期的客戶違約率約 13% 到 17%，逾期 1 個月升到 34%，逾期 2 個月高達 69%。另外，-2、-1、0 代表不同的繳款方式，不是逾期程度，所以這個欄位不能直接當成連續數字使用。
- 需要留意：教育程度有 0、5、6 等未定義的代碼，婚姻狀態也有 0；另外有 1,930 位客戶曾出現負的帳單金額，代表溢繳。



資料前處理與特徵工程
DATA PREPROCESSING

資料清理

在資料清理上，因為沒有遺失值，所以不需要補值或刪除資料。

特徵工程

- 在特徵工程上，原始資料有 18 個逐月欄位，相鄰月份的帳單金額高度相關。我把它們濃縮成 9 個行為特徵，分成帳單、繳款、逾期三組，每組都看「水準」「極值」和「趨勢」，例如近 3 個月的逾期次數是否比前 3 個月多。最近一個月的 PAY_0 則保留原值。
- 最後模型使用 15 個特徵：5 個基本資料、PAY_0 和 9 個聚合特徵，特徵數從 23 個降到 15 個，也達到降維的效果。

資料分割

先分割再標準化。以 8:2 切成 24,000 筆訓練集和 6,000 筆測試集，再做標準化，而且只用訓練集計算平均與標準差，避免測試集的資訊洩漏。

THYNK
UNLIMITED

模型選擇與訓練
MODEL SELECTION & TRAINING

07

演算法選型

在演算法選型上，我選了四種分類方法。邏輯斯迴歸容易解釋，作為基準模型；KNN 用最相似的客戶來判斷，k 值用交叉驗證從 1 到 39 中選出 39；決策樹和支援向量機 SVC 則能捕捉非線性關係。

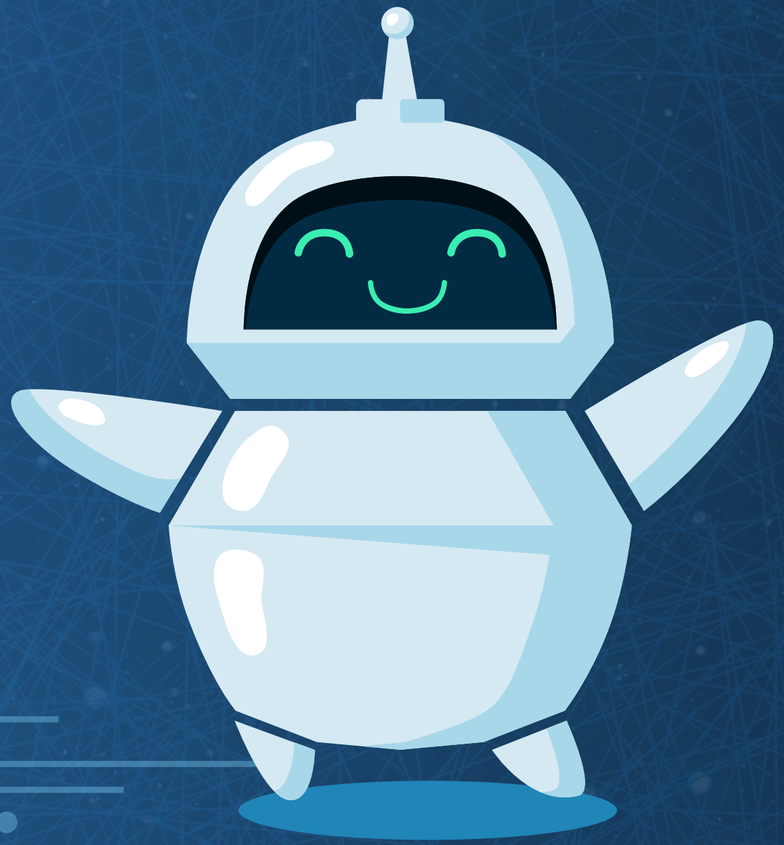
模型訓練

訓練過程中有兩個重要發現：

1.不限深度的決策樹訓練準確率達 99.9%，測試却只有 73%，明顯過度擬合，所以我把深度限制為 5。

2.我原本用 Hard Voting 集成，它只輸出 0 或 1，沒有機率，所以算出的 Log Loss 並不正確。因此改用 Soft Voting，平均 SVC、決策樹和邏輯斯迴歸的違約機率；此外，SVC 本身不輸出機率，所以先經過機率校準。





結論
ANALYSIS RESULT

- **SOFT VOTING** 組成：校準後的 **SVC** + 決策樹（深度 **5**）+ 邏輯斯迴歸
- **HARD** → **SOFT**：取得違約機率，才能正確計算 **LOG LOSS**

模型	Accuracy	F1	AUC	Log Loss（越低越好）
Soft Voting	**0.818 ± 0.001**	**0.460 ± 0.009**	**0.774 ± 0.005**	**0.437 ± 0.002**
KNN（k=39）	0.813 ± 0.002	0.446 ± 0.008	0.764 ± 0.004	0.470 ± 0.019
邏輯斯迴歸	0.807 ± 0.003	0.405 ± 0.012	0.753 ± 0.003	0.448 ± 0.002

THANK YOU.

